Optimización en Regresión Lineal

Reporte realizado por: Edson David Texon Lozano

Resumen*—En el presente trabajo se abordó el problema de modelar la relación entre el área de una propiedad y su costo de renta mediante un modelo de regresión lineal simple. Para simplificar el proceso de estimación de parámetros, se aplicó una estrategia de centrado de datos, lo que permitió reducir el modelo a una sola variable: la pendiente. Posteriormente, se utilizó un método de optimización por búsqueda exhaustiva dentro de un rango definido para encontrar el valor de la pendiente que minimiza la suma de errores cuadrados (SSE). Los resultados obtenidos fueron validados mediante una solución analítica y analizados a través de representaciones gráficas.

I. Introducción

La regresión lineal constituye una herramienta fundamental en el análisis de datos, ya que permite modelar la relación entre una variable independiente y una variable dependiente mediante una función lineal. En este estudio, se analiza la relación entre el tamaño de una propiedad, medido en metros cuadrados, y su costo de renta, expresado en miles de pesos. El modelo general se expresa como una ecuación lineal en la que la pendiente representa el cambio en la renta por cada unidad adicional de área, mientras que la intersección corresponde al valor base de la renta.

Con el objetivo de facilitar el proceso de optimización, se implementó una transformación de los datos mediante el centrado de las variables. Esta técnica consiste en restar la media de cada variable a sus respectivos valores, lo cual desplaza el sistema de coordenadas al origen. Como resultado, la recta de regresión pasa por el punto (0,0), eliminando la necesidad de estimar la intersección y permitiendo enfocar el análisis exclusivamente en la pendiente del modelo.

.

II. Herramientas y materiales

Para la realización de esta tarea se utilizaron las siguientes herramientas y recursos:

- Lenguaje de programación: Python
- Librerias usadas:
  - Numpy: Para cálculos numéricos y manejo de los datos.
  - Matplotlib: Generacion de graficos
- Tecnicas:
  - Regresion Lineal
  - Centrado de datos

III. Metodología:

El procedimiento inició con el centrado de los datos originales, calculando las medias de las variables de entrada y salida, y transformando cada observación en función de dichas medias. Esta transformación permitió redefinir el modelo de regresión como una relación directa entre las variables centradas, en la que únicamente se requiere estimar la pendiente.

Posteriormente, se definió la función objetivo como la suma de los errores al cuadrado (SSE), la cual mide la diferencia entre los valores reales y los valores predichos por el modelo. El objetivo principal fue encontrar el valor de la pendiente que minimiza esta función, garantizando así el mejor ajuste posible a los datos.

Para resolver este problema, se implementó un método de búsqueda exhaustiva, evaluando múltiples valores de la pendiente dentro del intervalo [0, 1], con incrementos de 0.001. Para cada valor se calculó el SSE correspondiente, y se seleccionó aquel que produjo el menor error. Finalmente, los resultados obtenidos se compararon con la solución analítica derivada de la fórmula cerrada de la regresión lineal, con el fin de validar la precisión del método numérico.

IV. Resultados

Los resultados obtenidos muestran que el valor óptimo de la pendiente es aproximadamente $\beta_1 \approx 0.298$, lo cual coincide con el valor obtenido mediante la solución analítica. Este resultado indica que el modelo encontrado es consistente y que el método de optimización empleado fue adecuado.

El análisis gráfico permitió complementar estos hallazgos. En la gráfica de comparación de pendientes se observó que las rectas con valores bajos de la pendiente subestiman los datos, mientras que aquellas con valores altos los sobreestiman. En contraste, la recta correspondiente a $\beta_1 \approx 0.3$ es la que mejor sigue la tendencia de los datos, evidenciando un ajuste más preciso.

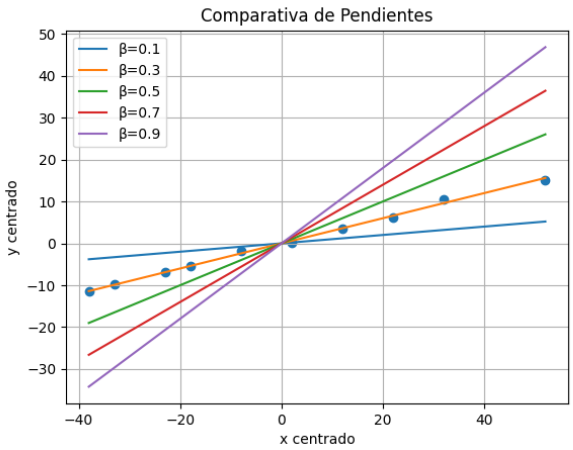

Por otro lado, la gráfica del paisaje del error mostró una curva con forma parabólica, característica de una función convexa. Esta forma confirma que existe un único mínimo global, el cual corresponde al valor óptimo de la pendiente. Además, se observó que el error aumenta progresivamente a medida que la pendiente se aleja de este valor, lo que refuerza la validez del resultado obtenido.

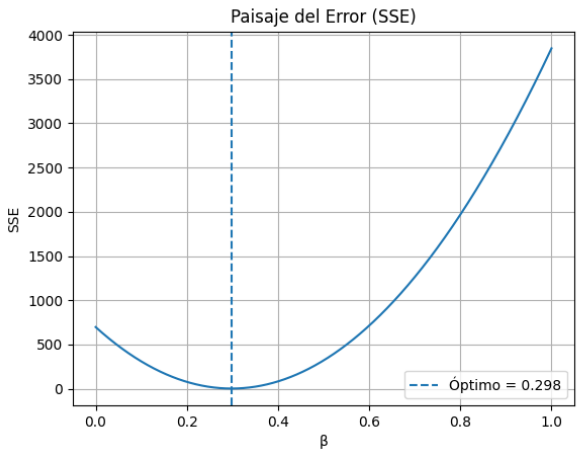


```
PS C:\Users\e_dso> python -u "c:\Users\e_dso\Downloads\Regresion Lineal.py"
Media de x: 68.0
Media de y: 19.97

Beta óptima: 0.298
Error mínimo: 1.9578
Beta analítica: 0.2983
```

V. CONCLUSIÓN

El centrado de los datos resultó ser una estrategia clave para simplificar el problema, al reducir el número de parámetros a estimar. Asimismo, la coincidencia entre los resultados numéricos y analíticos confirma la correcta implementación del método.

El análisis gráfico desempeñó un papel fundamental al proporcionar una interpretación visual del comportamiento del modelo y de la función de error. En particular, la convexidad del SSE garantiza la existencia de una solución única, lo que facilita el proceso de optimización.

Finalmente, el valor de la pendiente obtenido tiene una interpretación práctica clara: por cada metro cuadrado adicional, la renta aumenta aproximadamente 0.298 miles de pesos, es decir, cerca de 298 pesos. Esto confirma la existencia de una relación lineal positiva entre el tamaño de la propiedad y su costo de renta, lo que valida la pertinencia del modelo utilizado.